



内容列表可在ScienceDirect上找到

生物学和医学中的计算机

杂志主页: www.elsevier.com/locate/combiomed

基于EEG通道相关的情绪识别

模型

Md.Rabiul Islam^{a,b}, Md.Milon Islam^c, Md.Mustafizur Rahman^d, Chayan Mondal^b, Suvojit Kumar Singha^b, Mohiuddin Ahmad^b, Abdul Awal^e, Md.Saiful Islam^f,
穆罕默德-阿里-莫尼^{g,*}

^a 电气和电子工程, 孟加拉国陆军工程与技术大学, 纳托尔, 6431, 孟加拉国^b 电气和电子工程, 库尔纳工程技术大学, 库尔纳, 9203, 孟加拉国^c 计算机科学与工程, 库尔纳工程技术大学, 库尔纳, 9203, 孟加拉国^d 电气和电子工程, Jashore科技大学, Jashore, 7408, 孟加拉国^e 电子和通信工程, 库尔纳大学, 库尔纳, 9208, 孟加拉国^f 格里菲斯大学信息和通信技术学院, 澳大利亚黄金海岸。^g 昆士兰大学健康与康复科学学院, St Lucia, QLD, 4072, 澳大利亚

我的朋友们, 你们知道吗?

关键词。

情感

卷积神经网络 特征提取

脑电图

皮尔逊相关系数 复杂度

ABSTRACT

使用人工智能 (AI) 进行情感识别是改善人机交互 (HCI) 的一个基本前提条件。从脑电图 (EEG) 中识别情绪已被全球接受, 在许多应用中, 如智能思维、决策、社会沟通、感觉检测、情感计算等。然而, 由于脑电图信号的振幅变化与时间相关性太低, 从该信号中正确识别情绪已变得非常具有挑战性。通常情况下, 需要付出相当大的努力来确定适当的特征或特征集, 以建立一个有效的基于特征的情感识别系统。为了减轻人工提取特征的工作量, 我们提出了一个基于机器学习的深度模型

与卷积神经网络 (CNN)。首先, 一维EEG数据被转换为Pearson's

相关系数 (PCC) 的特点是EEG子带的通道相关图像。然后, 这些图像被送入CNN模型以识别情绪。我们进行了两个协议, 即协议1识别两个级别, 协议2识别显示情绪的价值和唤醒的三个级别。我们调查发现, 只有PCC特征图像的上三角部分减少了计算的复杂性和内存的大小, 而不妨碍模型的准确性。使用国际授权的DEAP数据集, 在情绪上获得了78.22%的最大准确率, 在唤醒上获得了74.92%的准确率。

1. 简介

情绪是一种感觉, 它意味着我们在特定情况下如何行动。现在, 在技术发展的时代, 由于其非侵入性的特点, 从EEG识别情绪的研究已经变得非常流行。基于情感的非侵入式脑机接口 (BCI) 和信号处理技术有了显著的发展。因此, 基于EEG的情绪识别分析已成为情感计算中一个非常有吸引力的问题。各种形成中的重要数据可以很容易地从人脑中提取出来, 并进行分析, 以了解人类的内在真相。

如今, 机器特别是机器人已经被用于许多领域。

工业、医院, 甚至是家庭应用中。随着机器人在日常生活中的许多地方变得越来越普遍, 人们对机器人提出了更高的期望。为了更好地进行人机互动, 人们希望机器人具有决策、自我思考、情感感应的超级能力。情感识别的保证是一个不可避免的需求, 以使机器人在现实生活中的应用更加实用。病人的Affective有效的信息, 包括情绪状态, 被认为是他/她精神和身体状况的一个关键因素。病人的情绪状态对治疗管理过程有重大影响[1]。因此, 诊所、医院和其他医疗机构应该保持一个适当的情绪状态评估系统, 以加强医疗保健。由于人类行为主要取决于情感和心理学家

* 通讯作者。

电子邮件地址: rabiul.kuet.bd@gmail.com (Md.R. Islam), milonislam@cse.kuet.ac.bd (Md.M. Islam), mustafizur.170710@gmail.com (Md.M. Rahman), chayan.eee.92@gmail.com (C. Mondal), singha10.suvojit@gmail.com (S.K. Singha), ahmad@eee.kuet.ac.bd (M. Ahmad), m.awal@ece.ku.ac.bd (A. Awal), saiful.islam@griffith.edu.au (Md.S. Islam), m.moni@uq.edu.au (M.A. Moni)。

<https://doi.org/10.1016/j.combiomed.2021.104757>

2021年5月8日收到; 2021年8月5日收到修订版; 2021年8月6日接受

可于2021年8月10日上网

0010-4825/© 2021 Elsevier Ltd.。保留所有权利。




图1.使用CNN从EEG信号中识别情绪。

想分析人类的心理状况；对情绪的识别也成为心理学的一个热门话题。许多心理学实验证明了情绪与EEG信号之间的关系[2,3]。甚至情绪现在也被当作音乐和视频推荐的治理者。例如，在悲伤的情绪中，它推荐一个有趣的事件来使人快乐。在游戏中，在积极的情绪状态下，关卡可能变得更难。在法庭上，在犯罪的过程中对当事人的陈述、情绪也可以进行记录，以判断其真实性。和可靠性。因此，情绪识别已经成为我们日常生活中不可分割的一部分。因此，计算机科学家、人工智能专家、生理学家和生物学家正在不断产生大量的研究，使用计算机技术来理解人类的情绪[4]。

情感识别的研究需要人类的情感激发信号。人类在现实生活中的活动中保持情绪激动。然而，要积累这种情况下的兴奋数据是非常困难的。在研究中，通常通过听音乐、看视频和玩与情绪有关的游戏来收集与情绪有关的EEG数据。在不同类型的刺激中，视听刺激对人脑信号产生了适当的刺激，因为视听刺激通过音频和视频背景影响人的思维[5]。为了识别人类的情绪，许多学者使用了各种原始信号的类型[6]。许多人使用EEG信号[2,7-9]和面部前推测[10,11]；还有少数人使用手势、语言信号[12]、自体神经信号[13]。当使用面部表情和语言信号时，受试者需要明确地表达情绪。此外，从面部表情来看，只有这些类型的情绪可以被分类，其影响将改变人脸结构。然而，那些内心感到高兴但没有通过面部表达的受试者不能被分类。因此，面部表情不被认为是一种好的情绪识别器的原始信号。对于语音信号，主体的情绪可以借助声音的强度进行分类。由于这个原因，这种类型的情感识别方法并不适用于自闭症患者。此外，那些不能说话的人也被排除在这种情绪识别方法之外。一些研究者试图从手势[14]和身体动作[15]中对情绪进行分类。身体有缺陷的人不能用肢体语言和手势来表达情绪。此外，自主神经系统由于其复杂的获取技术而不太适用。有趣的是，受试者不能控制自发产生的EEG信号。当我们从EEG中提取情绪时，那么那些不能说话或不能通过手势和姿势表达自己的人的情绪也可以被识别。此外，脑电信号采集方法不像多模态信号采集那样棘手。此外，成本低、无线灵活和便携的采集媒介使其更受欢迎。因此，对于任何时间、任何地点的任何类型的人来说，最好的、无与伦比的情绪识别信号就是脑电图。

不同的研究人员采用了多种方法和途径在识别和分类情绪方面[16-18]。最近，小波变换由于其在时域和频域的良好性能，已经成为一种普遍的分析方法[8]。脑电信号是一种微伏范围内的非线性、非稳定和不对称类型的信号。这种类型的信号的计算和分析是

太具挑战性。一些关于情绪识别的研究已经通过选择适当的特征和浅层机器学习进行了。

支持向量机 (SVM) 等算法[19-23]，k Nearest 邻居 (kNN) [19]，决策树 (DT)，或多层感知器 (MLP) 等。Soleymani等人开发了一种基于用户独立分析的情感识别方法。他们在准确率方面取得了很好的结果，比如在对3个类别进行分类时，情感的准确率为68.5%，唤醒的准确率为76.4%[24]。Zheng等人使用机器学习研究了稳定的EEG模式，并系统地评估了不同特征提取方法、选择和平滑的性能[25]。Atkinson和Campos提出了一种基于价值唤醒的方法，结合基于相互信息的特征选择方法和核分类器[26]。他们提出了一个基于EEG的脑机接口，以探索一组情绪类型，并纳入与信号预处理和分类有关的额外特征。在传统的特征提取方法中，正在考虑几个特征或特征集来训练识别系统。相比之下，深度学习消除了选择有用和重要特征的困难。它允许机器自动从输入数据集中学习特征，并将其学习转移到分类器中。

Långkvist等人提出了一个深度信念网络 (DBN) 架构以减少多模态睡眠数据的复杂性和必要性[27]。他们还恢复了分类阶段的时间消耗事实。Li等人使用差异熵特征与新型DBN，在情感状态识别任务上取得了11.5%和24.4%的改进[28]。Martinez等人使用CNN对四种不同的情绪状态进行分类，考虑了皮肤电导率和血量脉冲信号[29]。研究者Wen等人[30]提出了一种使用通道相关的方法，但他们没有使用与情绪相关的子带数据。另一位研究者在均值、中位数、标准差和许多其他时域特征上使用了深度和卷积神经网络[31]，但时域特征没有太大帮助。[32]的作者考虑到四个子波段，计算了多通道EEG数据的PCC。

本文提出了一种较低的情感识别方法。使用CNN从基于视听刺激的EEG信号中获取复杂性。架构流程图如下图1所示。情绪与 β 和 γ 子波段高度相关，与 α 子波段适度相关，而与 θ 子波段的联系很差。因此，尽管我们考虑了四个子波段，但我们只考虑了 α 、 β 、 γ 子波段。这使我们的信息更有意义，并降低了计算的复杂性。同样，我们证明了只有PCC特征图像的上三角部分对识别情感是很重要的。我们的工作使用了一个基于深度架构的卷积神经网络，因为它可以自动提取内部特征。因此，拟议研究的主要贡献如下。

- 1) 开发一种改进的情感识别方法，其计算复杂度较低，对内存的要求较低，处理的时间消耗较少；同时不妨碍性能。

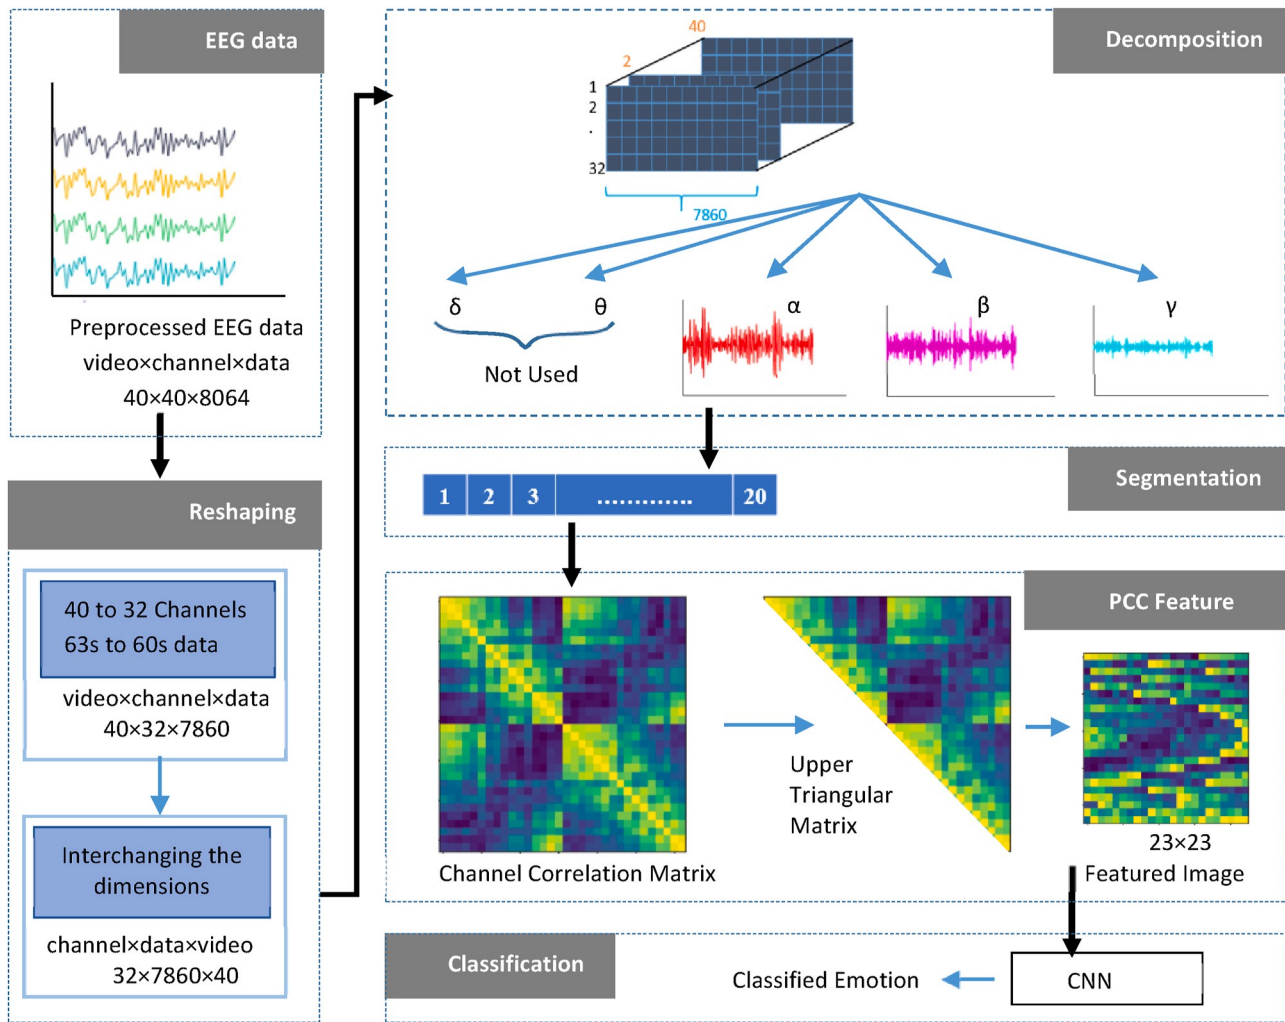


图2.我们提出的方法的连续过程包括重塑、分解、分割、PCC特征图像提取和分类，以从原始EEG数据中识别情绪。

- 2) 提出了一个新的程序，根据一维脑电信号的通道相关性，构建一个重要的二维数据矩阵。
- 3) 开发了一个基于CNN的修正模型，该模型可以利用EEG子带的单一特征Pearson's Correlation Coefficient识别情绪。

这项工作是我们以前工作[33]的更新版本。这里，在通过减少输入图像的大小，仅考虑PCC特征图像的上三角矩阵，计算复杂度大大降低。此外，卷积神经网络模型根据我们新生成的PCC特征图像的大小进行修改，作为输入。

本文的其余部分组织如下。第二节展示了必要的数据集收集和描述与数据预处理，包括一些预处理技术。此外，本节还描述了网络结构的发展。第三节说明了两个不同协议的DEAP数据集的经验-心理结果。讨论以及与当前工作的比较研究在第四节中进行了描述。最后，在第五节中讨论了结论和一些重要的未来工作。

2. 材料和方法

拟议的系统将EEG数据作为输入，并生成分类的

情感作为输出。我们实验的系统如图2所示。之后将分别描述系统的各个部分。首先，对原始EEG数据进行预处理。其次，只有一个命名为皮尔逊相关系数的特征在每个可能的32个通道中，两个通道的组合被确定。因此，我们制定了通道相关性的PCC特征图像。之后，包含二维通道相关数据的PCC特色图像被作为输入到我们设计的CNN分类算法中，以识别情绪。

2.1. 数据集

我们考虑了国际认可的“DEAP”数据集[34]在我们的研究中进行了实验，并测量了我们模型的表现。仍然有16个不同的基于情绪类的标记的脑电图数据，有32个参与者。DEAP”是指使用生理信号进行情绪分析的数据集。它是一个常用的情感分析开放数据集，包含脑电图、生理学和视频信号。

研究人员使用该数据集来评估他们自己设计的情绪识别系统的性能。16名男性和16名女性参与者（年龄范围从19岁到37岁）观看了40个不同的情绪音乐视频，并存储了相应的生理记录和参与者的评分。每个视频的长度为1分钟。他们使用国际脑电图仪记录脑电信号。

表1
关于'DEAP'数据集的信息。

属性细节信息	
脑电图采集系统	生物毫米公司的ActiveTwo
记录信号的通道	32个脑电图通道（512赫兹） 12 外围设备 1 状态通道 3个未使用的通道 总共 48个通道
脑电图	电极AF3, AF4, C3, C4, Cz, CP1, CP2, CP5, CP6, F3, F4, F7, F8, Fz, FC1, FC2, FC5, FC6, Fp1, Fp2, O1, O2, Oz, P3, P4, P7, P8 Pz, PO3, PO4, T7 和 T8
评定的 familiarity	参数Valence, arousal, dominance, liking, and 评定范围 1-9, 熟悉度除外 (1-5)。 可用的

据格式视频 × 通道 × 数据 = 40 × 40 × 8760




图3. 重塑和置换前后数据的三维尺寸。

10/20电极放置系统。关于'DEAP'数据集的相关信息见表1。由于脑电图信号是非常低的振幅信号，提取的从这种类型的信号中获取信息过于复杂。此外，一个如果不进行预处理，脑电图（EOG）和另一个噪声信号可能会妨碍原始信号的有效性。首先，将原始数据从512赫兹降频到128赫兹，以减少体积。后来，EOG伪影被去除。最后，将其通过频率为（4-45）Hz的带通滤波器。我们从 "DEAP "的官方网站上收集了预处理的数据。

2.2. 重塑和排列组合

在情感识别任务中，下载的数据形状格式就像视频通道数据40 40 8064。它说明了40个不同的视频，40个频道，8064个数据点（63s数据，采样频率128Hz，数据点128 63）。其中，只有第一个32个电极（通道）被用于记录脑电信号。因此，我们只提取了这32个通道的数据。另外，最后的60s数据是原始数据。我们将这些数据重塑为视频通道数据40 32 7680。之后，重塑后的数据被排列成以下格式的通道数据视频32 7680 40。图3显示了重塑和置换前后的数据结构。

2.3. 分解

人类的工作活动对脑电波产生全面影响。因此，可以从EEG信号中提取精神状态和条件。一般来说，人类的脑电图是一种复合型信号，由五

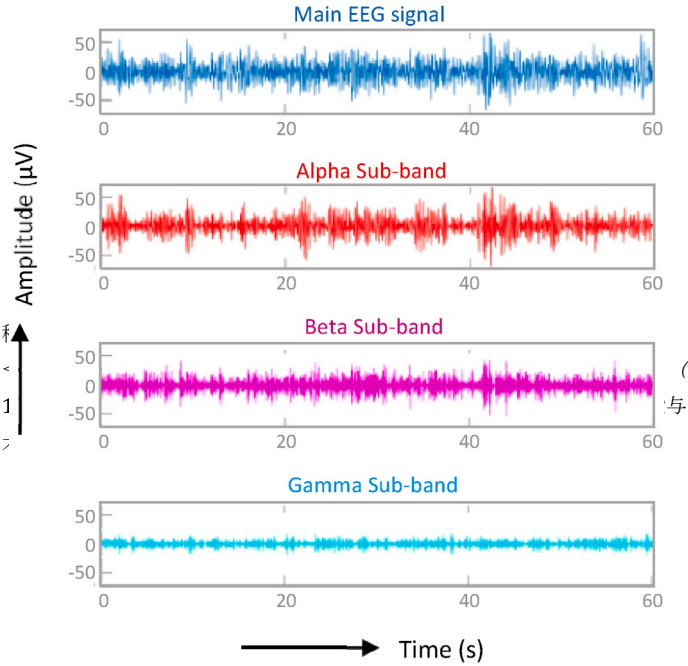


图4.将主要的预处理过的EEG信号（p1、v1、Fp1）分解为 α 、 β 和 γ 带信号。

图5.60年代的每个分解信号都被分割成20个部分。


活动，如深度睡眠和无意识。Theta和alpha子波段与低水平的兴奋有关，如昏昏欲睡、想象、闭眼等。中等水平的兴奋包括思考、焦虑和压力，与 β 子波段信号结合。最后，伽马子波段信号影响过度活跃，如警觉性、激动、物体匹配和感觉处理。在我们工作的这一部分，脑电图信号用离散小波变换分解成五个子波段。后来，由于delta和theta子带与放松的低水平大脑活动有关，我们忽略了它用于情绪识别。图4显示了第一段视频（v1）中第一个参与者（p1）的原始EEG信号和我们分解的Fp1通道的 α 、 β 和 γ 带信号。

2.4. 分割

由于CNN需要许多训练数据以获得独特的性能，因此必须对EEG数据进行分割。一个脑电信号的长度是60秒，这意味着总的数据点的数量是7680个。在计算不同通道的PCC之前，我们需要对数据进行分割。在这里，脑电信号被分割成20个部分，其中每个部分包含384个数据点（3s的数据）。单通道EEG的分割部分如图5所示。相应地，对于一个参与者，总的分割部分数量将是20乘以32乘以40，即25600个。

2.5. PCC特色图片的形成

为了从脑电信号中识别情绪，许多研究人员使用了各种类型的方法，如短时傅里叶变换。



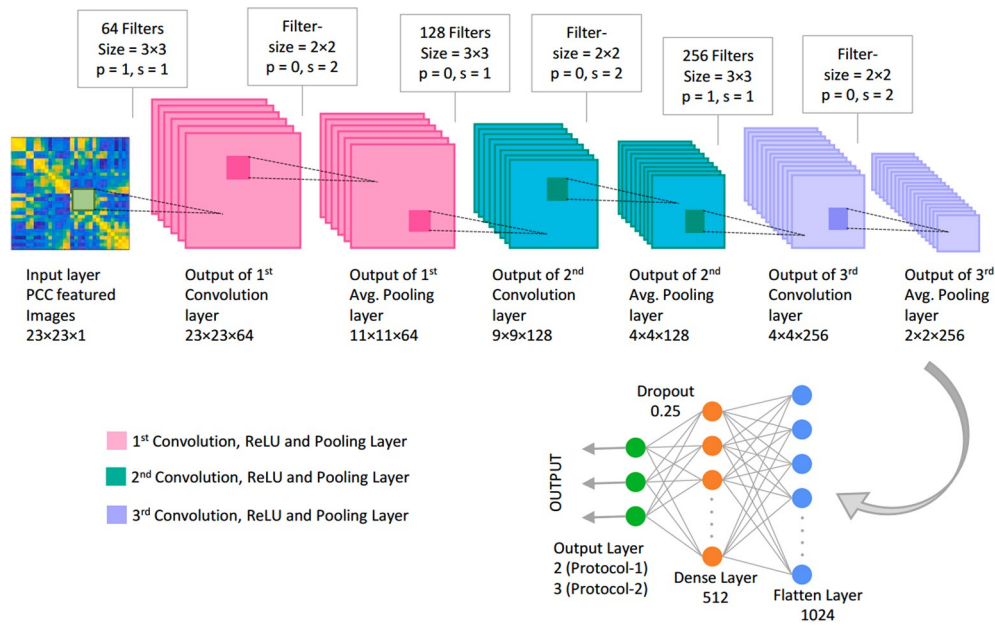


图6.所提出的用于情感识别的CNN模型由三组卷积层、整流线性单元（ReLU）和池化层组成，此外还有一个扁平层和一个密集层。图中显示了每一层的图像大小、过滤器数量、填充物和步长等。

(STFT), Common Spatial Pattern (CSP), Discrete Wavelet Transform, Statistical feature, Higuchi fractal dimension (HFD), Magnitude Squared Coherence Estimate (MSCE), Power Spectral Density (PSD), Fast Fourier Transform (FFT), Higher-Order component (HOC), Differential Entropy (DE), Differential Asymmetry (DASM), Rational Asymmetry, Affective Signal Processing (ASP), 等等。我们使用皮尔逊相关系数（Pearson's Correlation Coefficient）来生成具有PCC特征的有效图像，用于情绪识别。

皮尔逊相关系数是代表两个连续变量之间的统计关系的指示尺度。它是基于协方差的；它是衡量两个变量之间关系的最佳方法。Pearson's Correlation（皮尔逊相关系数）的值

系数范围从+1到-1，其中+1表示完全正数。

相关性，而-1则与此相反。数据集a和b的两个系列的PCC的计算方法是

$$\rho_{ab} = \frac{\text{cov}(a, b)}{\sigma_a \sigma_b} \quad (1)$$

其中 $a = (a_1, a_2, a_3, \dots, a_n)$, $b = (b_1, b_2, b_3, \dots, b_n)$ 。这里 $\text{cov}(a, b)$ 表示a和b之间的协方差， σ_a, σ_b 意味着标准的偏差的数据集a和b，分别。在我们的工作中，我们通过使用MATLAB中的一个用户定义的函数直接计算PCC (2)。

$$\rho_{ab} = \frac{\sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b})}{\sqrt{\sum_{i=1}^n (a_i - \bar{a})^2} \sqrt{\sum_{i=1}^n (b_i - \bar{b})^2}} \quad (2)$$

2.6. 卷积神经网络模型

卷积神经网络是深度神经网络（DNN）的一个分支，它已被证明具有出色的图像分类和计算机视觉性能。CNN的主要结构与人类神经元的连接模式非常相似。CNN的主要优点之一是它只需要一点点预处理，或者有时不需要像其他传统分类算法那样进行预处理。它可以自动从训练数据集中学习许多特征，并利用它们来预测测试数据。CNN的第一个操

在输入图像的特定部分和内核的特定形状之间进行矩阵乘法。

内核在图像中移动，并做出一个新的卷积图像。我们提出的从基于PCC的图像到分类情感的CNN架构如图6所示。在该架构中，仍然有三组。

卷积层、ReLU和Pooling层。之后，我们使用了扁平化层。最后，密集层被连接起来。在这里，我们使用了一个落差为0.25，以降低网络的复杂性。

经过一个卷积层， c 考虑到输入图像的大小，输出图像的维度将是 $n_h n_w$ ，过滤器、权重和偏置分别如 (3)、(4)、(5) 和 (6) 所示。

$$\text{输入的大小} = n^{[l-1]} \times n^{[l-1]} \times n^{[l-1]} \quad (3)$$

$$\text{滤波器的尺寸} = f^l \times f \times n^{[l-1]}_{HWC} \quad (4)$$

$$\text{权重的大小} = f^l \times f \times n^{[l-1]}_{HWC} \times n^l_c \quad (5)$$

$$\text{偏见的大小} = 1 \times 1 \times 1 \times n^l_c \quad (6)$$

l 层的输出层可按以下方式计算。

$$n_h^{[l]} = \frac{n_h^{[l-1]} - 2p^l - f^l}{s^l} + 1 \quad (7)$$

$$\text{输出的大小} = n_h^l \times n_w^l \times n_c^l \quad (8)$$

作是与图像和过滤器进行卷积。在神经网络的讨论中，滤波器和内核是一个术语。卷积层是任何CNN网络的主要层。该层

n_w 的计算恰好与 n_H 类似 (7)。这里, $p[l]$ 和 $S[l]$ 分别代表一个级别的padding和stride值。在第1、2、3卷积层中使用了大小为3 3的滤波器。滤波器的数量如图6所示。由于我们不希望丢失基于PCC的输入图像中某个角落的像素的信息,我们在第1和第3卷积层中使用了相同的卷积(填充层, $p = 1$)。第2个卷积层使用了有效的卷积(即没有填充, $p = 0$)方法,以减少计算的复杂性。图6清楚地表明了每一层中的填充 (p) 和跨度 (s) 的数量。

在正常图像的分类任务中,最流行的池化类型是最大池化。由于PCC特征图像是纹理型图像,尽管使用了最大集合,我们还是使用了平均集合。这可能是

$$\begin{aligned} & \times \\ & = \\ & = \end{aligned}$$

表2

我们训练的CNN模型的主要超参数的值或类型。

模型超参数值或类型	
学习率	0.001
动量	0.80
历时数	50
批量大小	512
辍学	0.25
集合	方法平均集合
激活	函数ReLU和sigmoid（用于协议1） ReLU和softmax（用于协议2）
优化	。算法阿丹

注意到纹理型图像不像普通或自然图像那样包含任何特定的图案。在每一个汇集层中都使用了跨度为2的2 2大小的过滤器。主要的超参数及其相应的信息，如我们训练的CNN模型的值或它们的类型，如表2所示。

2.7. 激活功能

在我们的模型中，使用了ReLU激活函数，它最适合CNN架构，而且速度更快。与 "sigmoid "和 "tanh "相比，ReLU有一个积极的特点，即在x的一个重要值时不会饱和，此外，它更可靠，并将收敛速度提高了六倍。ReLU的数学表达式在（9）中给出。

$$f(x) = \max(0, x)$$
 (9)

由于我们的输入数据是由1到1的数值组成的，所以这里没有必要进行归一化。我们使用l2型核正则器来消除密集层中的过拟合现象，正则参数为0.001。在协议1中，我们进行了二元分类。为了做到这一点，我们在最后一层使用了 "sigmoid "激活函数。sigmoid "是一个平滑的非线性激活函数，它返回一个类别的概率，由于概率范围从0到1，它的范围也是一样的。sigmoid "激活函数的方程式在（10）中给出。协议2不是一个二进制分类任务，因为我们把价值和唤醒分为三个类别。因此，"sigmoid "不适合这个目的。对于多类分类，"softmax "激活函数是完美的。softmax "激活函数返回每个类别的概率，最后，它的目标是属于最重要的概率的类别。softmax "函数定义在（11）中。

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$
 (10)

$$h_{\theta}(x) = \frac{1}{1 + \exp(-\theta^T x)}$$
 (11)

这里，h是'softmax'的标量输出，范围为h (x)∈R和0 < h (x) < 1。θ和x分别是权重和输入值的向量。

2.8. 优化算法和成本函数

在神经网络中，更新模型参数如权重和偏置值需要一个优化算法。优化算法运行一个寻找最佳或满意解决方案的程序。优化算法的主要目

表3

二元和多类分类问题的成本函数。

函数	问题类型输出	层的 配置	成本
二进制	一个具有 "sigmoid "激活函数的节点	二元交叉熵分类交	
分类多类	。	叉熵	
分类	每个类别有一个节点，使用		
	'softmax'激活函数。		

表4

协议1中我们的CNN模型的形状和参数值。

层	(类型) 输出	形状参数
输入	23, 23, 1-	
Conv_1	(Conv2D)23, 23, 64	640
平均池_1	(AveragePooling) 11, 11, 64	0
Conv_2	(Conv2D)9, 9, 128	73856
平均池_2	(AveragePooling)4, 4, 128	0
Conv_3	(Conv2D)4, 4, 256	295168
平均池_3	(AveragePooling)2, 2, 256	0
扁平化_1 (扁平化)	1024	0
密集_1	(Dense)512	524800
辍学_1	(辍学)512	0
密集_2	(Dense)2	1026
总参数:	895,490	
可训练的参数:	895,490	
不可训练的参数:	0	

表5

协议2中我们的CNN模型的形状和参数值。

层	(类型) 输出	形状参数
输入	23, 23, 1-	
Conv_1	(Conv2D)23, 23, 64	640
平均池_1	(AveragePooling) 11, 11, 64	0
Conv_2	(Conv2D)9, 9, 128	73856
平均池_2	(AveragePooling)4, 4, 128	0
Conv_3	(Conv2D)4, 4, 256	295168
平均池_3	(AveragePooling)2, 2, 256	0
扁平化_1 (扁平化)	1024	0
密集_1	(Dense)512	524800
辍学_1	(辍学)512	0
密集_2	(Dense)3	1539
总参数:	896,003	
可训练参数:	896,003	
不可训练的参数:	0	

算法总是更新权重和偏差的值，以减少损失的值。在协议1中，输出类的数量M=2，交叉的熵是用（12）来计算的。同样地，在第二方案中，由于输出类的数量为3，分类交叉熵为由（13）计算得出。输出层的配置和相关费用的是使神经网络模型的损失或误差最小化。一些流行的优化算法的例子是随机梯度下降（SGD）、批量梯度下降（BGD）、Nadam（Nesterov Adam优化器）、Adagrad（自适应梯度）、Adadelat（自适应三角）、Adam（自适应矩估计）、Adamax、RMSprop等。自适应矩估计（Adam）梯度下降算法被用来优化我们的神经网络。一个完美的神经网络的主要目标不是提高精确度，而是减少损失。优化

成本_{p=1} = - [y log(p) + (1 - y)log(1 - p)] (12)

成本_{p=2} = -y_{o,c}^Mlog P_{o,c} (13)

其中'M'表示输出类别的数量，'y'是定义正确或不正确分类的二进制指标（0,1），'P_{oc}'意味着对'c'类观察'o'的预测概率。

我们使用 "Google-Colab "用户界面来执行代码。表4和表5分别显示了所提出的情感识别模型的摘要。可以注意到，除了最后一个密集层的输出形状外，这两个架构几乎是相同的。由于我们在协议1和2中分别分类了2和3个不同的类别，最后一个密集层的形状是2和3。




图7.随机抽样的PCC特色图像，其中每个像素都表示相关双通道数据的PCC。(a) 第1号参与者的图像，第1号视频，第1段 (b) 第1号参与者的图像，第1号视频，第2段 (c) 第15号参与者的图像，第20号视频，第7段 (d) 第31号参与者的图像，第20号视频，第7段。

3. 结果

\leq
 \leq

规模为低：0值4.5和高：4.5<值9。在协议-2中，低价值和唤醒的中度和高度是通过以下方式区分的

在我们的实验中，我们使用脑电信号的 "DEAP "数据集来进行情绪分类。与情绪有关的EEG信号首先被转换为PCC特征图像。在这里，我们计算了以下的相关性

对于同一情感视频和同一分割的不同通道数据。这个通道相关矩阵包含类似分割的每两个通道组合之间的PCC。因此，可以为每个分割找到大小为32 32的矩阵。由于在每个60年代，脑电信号被分割成20个片段，而一个参与者展示了40个不同的情绪视频；总的方形矩阵的数量将是20 40 800。因此，对于32个参与者来说，800 32，即25600个通道相关的方形矩阵是为一个子带产生的。基于通道相关的图像

图7显示了一些基于PCC的图像样本，其中 "p "表示某个参与者，"v "表示视频，"s "表示片段编号。一些基于PCC的图像样本如图7所示，其中 "p "表示某个参与者，"v "表示视频，"s "表示片段编号。之后，这些图像被送入基于CNN的分类系统。

cation算法。在协议-1中，我们区分了低水平和高水平的价值和唤醒。

在这里，级别的区分是通过以下方式进行的

在低：0值3，中：3<值6和高：6<值9的范围内。

Alarcao和Fonseca[7]以及Zheng和Lu[9]发表了他们的调查，发现情绪与β和γ波段密切相关，与α波段适度相关。此外，θ波段也有轻微的活动，这取决于情绪。相反，δ波段与无梦和深度睡眠、无意识思维和非常相关。

与情绪的关系很差。因此，我们考虑了除δ、θ和主脑电图数据以外的三个子波段，用CNN提取情绪。

由于我们使用了一组25600张主频和三个子频的PCC特色图像，所以总共还有25600张

4 102,400张有标签的PCC特色图像。这些数据被分为训练（90%）、验证（5%）和测试（5%）数据。在训练期间，该模型验证了验证部分所选数据的准确性。图8和图9显示了情绪和唤醒的2类和3类分类的准确性和损失。从这些图中可以看出，两个协议的最小损失都发生在45到50个历时之间。由于在机器学习方法中，损失的最小化比准确度的最大化更可取，我们用50个历时来训练这个系统。

我们模型的混淆矩阵如图10所示。图中的

× =

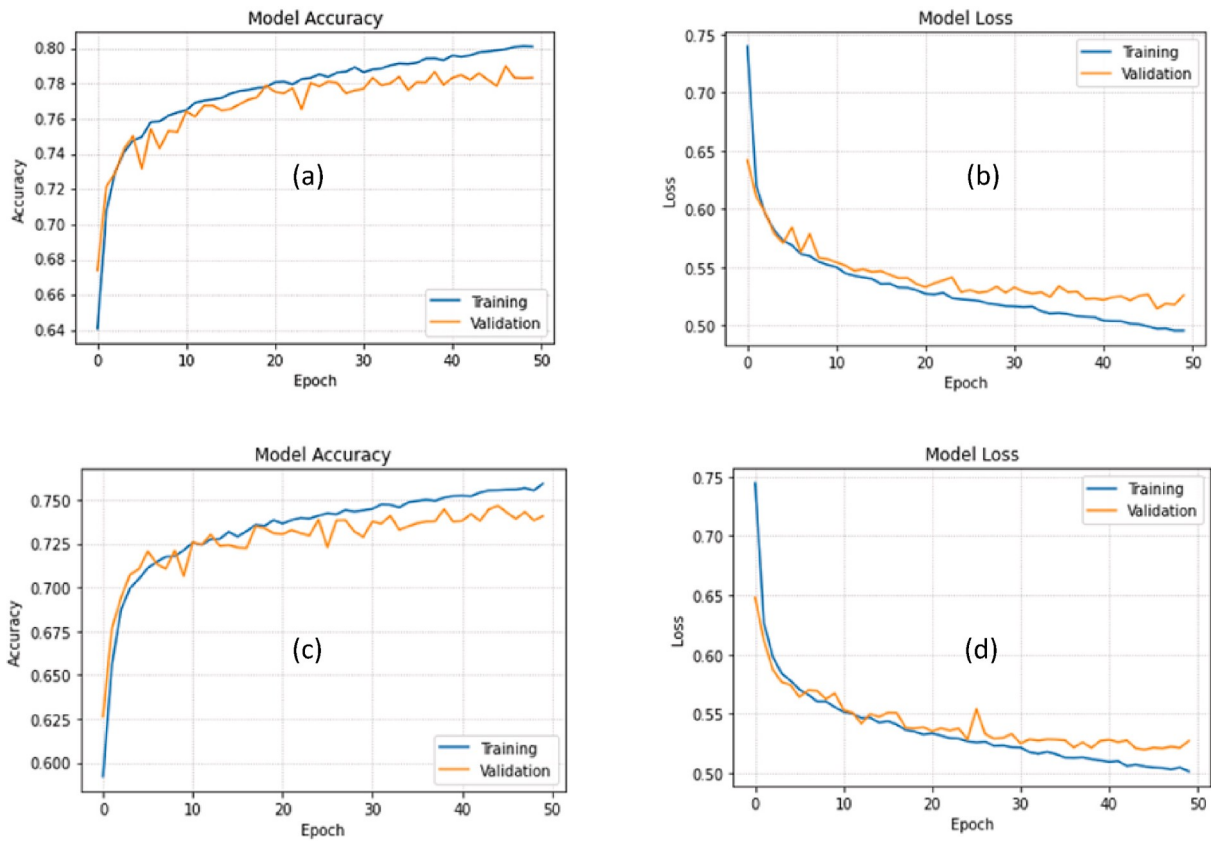


图8.两类分类的模型准确性和损失曲线。(a) 情绪的准确性, (b) 情绪的损失, (c) 兴奋的准确性, (d) 兴奋的损失。

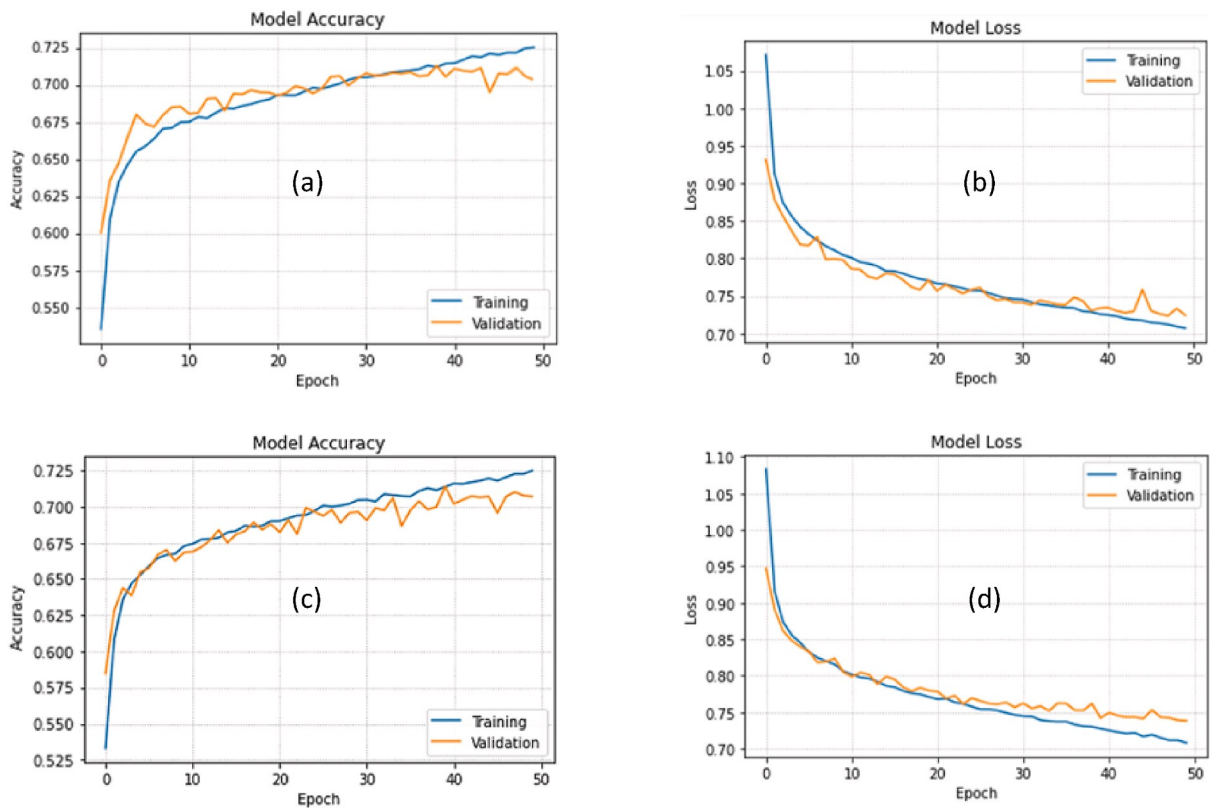


图9.三类分类的模型准确性和损失曲线。(a) 情绪的准确性, (b) 情绪的损失, (c) 兴奋的准确性, (d) 兴奋的损失。

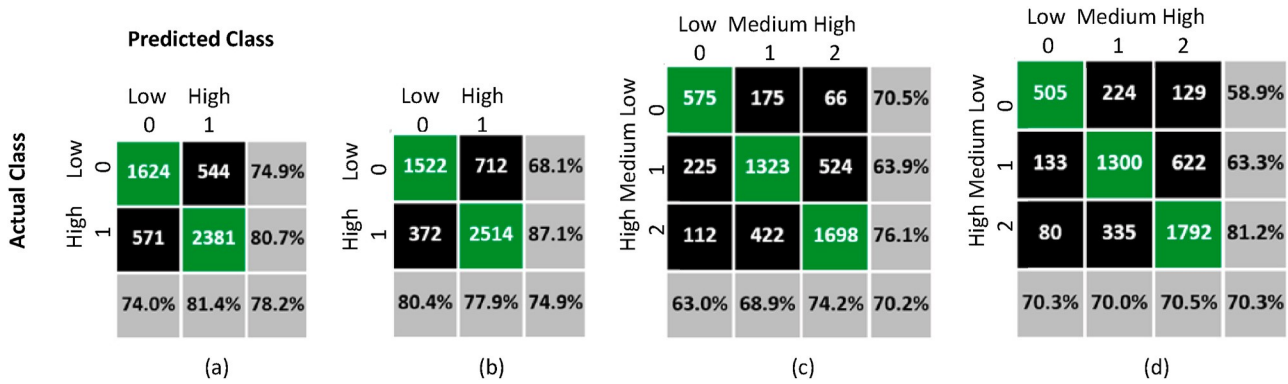


图10.混淆矩阵 (a) 两类情感 (b) 两类唤醒 (c) 三类情感, (d) 三类唤醒。

表6

我们模型的分类结果。

情绪化/亢奋	级别	精度	召回	F1得分	支持
协议1: 0 ¼ 低, 1 ¾ 高					
缬氨酸	0	0.74	0.75	0.74	2168
	1	0.81	0.81	0.81	2952
唤醒	0	0.80	0.68	0.74	2234
	1	0.78	0.87	0.82	2886
协议2: 0 ¼ 低, 1 ¼ 中, 2 ¾ 高					
Valence00.630.700.66					816
唤醒	1	0.69	0.64	0.66	2072
	2	0.74	0.76	0.75	2232
	0	0.70	0.59	0.64	858
	1	0.70	0.63	0.66	2055
	2	0.70	0.81	0.75	2207




图11.只考虑上三角矩阵的复杂度降低。

表7

基于输入大小、参数、执行的计算复杂度降低。

在新模式下的处理时间。

减少复杂性的因素	输入	尺寸总数	执行时间 (50
		可训练的参数	个纪元的执行
议定书-1			
旧模式	$32 \times 32 = 1024$		1,550,850351s
新模式	$23 \times 23 = 529$		895,490207s
复杂度降低(%)			48.34%42.59%41.03%
议定书-2			
旧模式	$32 \times 32 = 1024$		1,551,363302s
新模式	$23 \times 23 = 529$		896,003101s
复杂度降低(%)			48.34%42.24%66.56%

CNN模型发送PCC矩阵之前, 将

四个独立的混淆矩阵是为两类情感、两类唤醒、三类情感和三类唤醒的分类任务产生的。在每一个混淆矩阵中, 最后一行代表的数值是

的精度, 最后一列代表召回率的数值。此外。

最后一行和最后一列数据表示具体任务的准确百分比。

包含两个不同协议的每一类的精度、召回率、F1分数和准确率的总

体分类报告是

在表6中给出。F1分数的高值表明准确率和召回率的重要性是平衡的, 并且令人满意。

两种协议都是如此。

这里, 只考虑了通道间的相关性。通道间的

通道相关性更有意义, 因为人脑在短短几秒钟内 (1s-4s) 就会被任何单一的情绪刺激唤醒。另一方面, 样本间的相关关系可能是另一种选择

对于未来的工作。它很重要, 因为它允许人们考虑不同情绪状态下EEG信号的时间特征的变化。此外, 样本间相关技术将扩大数据量, 促进大尺寸数据的深度机器学习算法性能。

4. 讨论

如前所述, 为了识别情感, 首先生成了基于通道相关的PCC特征图像。大小为3232的PCC特征图像由图7中清楚显示的对角线对称矩阵组成。由于对角线元素代表了相同通道之间的相关性, 所有的PCC矩阵的值都是1。因此, 在每张图像中, 对角线元素的颜色都是黄色。

由于基于PCC的单幅图像的上三角矩阵数据或下三角矩阵数据是相同的, 所以没有必要在双倍时间内使用相同的数据。因此, 在向我们的

下三角数据被删除。因此，数据点从1024（32 32）减少到528（12 32），如图11所解释。在这528个数据点中增加了一个额外的0数据，以形成一个新的形状的PCC特色图像，大小为23 23。最终，只有51.1%的基于PCC的图像的方形矩阵的数据点被送入CNN模型，因为这些点包含了情绪识别的重要信息。使用这种技术，内存的大小和计算的复杂性已经减少，而不会降低情绪识别的准确性。

输入图像的数据点从1024个减少到529个，表明仅在执行的这一步就减少了48.34%的内存。考虑到一些特定的因素，表7给出了协议1和2中复杂性的降低。在协议1中，总的可训练参数从1,550,850减少到895,490，这意味着整个程序的计算量减少了42.59%。我们使用了'Google Colab'的GPU，并通过配置英特尔（R）酷睿（TM）i5-8250U CPU的笔记本电脑进行5Mbps的互联网连接。1.60 GHz，7.88 GB DDR4内存，256 GB SSD，64位操作系统用于

×+ ++

×

表8
不同情感识别方法的比较。

作者	提取的特征	分类器	分类的数量 感情	准确率(%)	数据集
Koelstra等人 (2011年) [34]。	多媒体内容分析 (MCA)	高斯奈夫贝叶斯分类器	4 (HVHA, HVLA, LVHA, LVLA)	电价=57.6	DEAP
Jirayucharoensak等人 (2014年) [35]。	功率谱密度 (PSD)	带有SAE的深度学习网络	3级	唤醒=62.0 电价=49.5	DEAP
Ackermann等人(2016) [4]	统计学特征	SVM和随机森林	3 (愤怒、惊讶等)。	唤醒=70.0 平均准确率=55	DEAP
Tripathi等人 (2017) [31]]统计学特征在时间和 频域	卷积神经网络 (CNN)	2 (低, 3 (低、中、高)	高) 价= 唤醒=73.4 电价=66.7 唤醒=57.6	81.4DEAP
Song等 (2018) [36]]PSD与	图Dynamical Graph Convolutional Neural Networks (DGCNN)。	2 (低, 高)	Valence= (86.2 ± 12.3) 唤醒= (84.5 ± 10.8) 支配度= (85 ± 10.3)	DREAMER
Cheng等 (2019) [37]]考虑到 二维框架序列 空间位置		深林2 (低, 高)	价值= (97.69±) 1.22) 唤醒= (97.53 ±) 1.52) 效价= (89.03 ± 5.56) 唤醒= (90.41 ±) 5.33) 优势= (89.89 ± 6.19) 总体准确性= 71.0 高)价= 唤醒=74.92 电价=70.23 唤醒=70.25	DEAP DREAMER
Fang等人 (2020) [38]]功率谱密度 (PSD) 和 微分熵 (DE) 佩尔森的相关系数 (PCC)	多特征森林。 卷积神经网络 (CNN)	(MFDF) 5 (愤怒, 愉快的, 和中性的) 2 (低, 3 (低、中、高)		DEAP 78.22DEAP
我们的方法, P1					
我们的方法, P2					

执行我们的编程代码。通过使用相同的处理器和相同的网速，新模型也需要更少的时间来执行。50个历时的总时间从351s减少到207s。同样，在协议-2中，（见表7）；新模型显示在输入大小、总参数数量和执行时间方面的复杂性分别减少了48.34%、42.24%和66.56%。

我们提出的模型的总体准确率如表8所示。在表8中，表示两类价值和唤醒识别任务的准确性分别为78.22%和74.92%。在三类分类中，价值和唤醒识别任务的准确率为70.23%和70.25%。另一个重要的事实是，协议-1的准确率百分比相对来说要高一些。

协议-2的。其原因是，只要要分类的类的数量增加，那么损失也会增加。因此，准确性会下降。从像我们这样的工作的比较表中，我们提出的方法的准确性确实令人满意。准确率不是最高的，那么它怎么能被接受呢？我们的目标不是设计一个最高精度的模型，目标是开发一个计算复杂度较低、所需内存和时间较少的模型。例如，Tripathi等人[31]的模型使用了很多特征，而我们只使用了一个名为PCC的特征。此外，仅在2类价位上的准确度较高；相反，其余的准确度则低于我们的方法。Song等人的模型也是如此。

[36]非常有效，但由于数据集与我们的不一样，在这里适当的比较没有太大意义。最近，一些基于深度学习的模型，如基于深度森林的模型[37,38]和基于特定节奏的深度学习模型[39]在情绪识别方面表现非常好。Cheng等人[37]在考虑跨通道空间位置的二维帧序列上使用深度森林算法。他们将其应用于DEAP和DREAMER数据集，并取得了表8中所述的准确性方面的顶级结果。Fang等人[38]使用多特征深度森林作为PSD

和DE的分类器。

特征，并将情感分为五类。该模型使用DEAP数据集进行了测试，取得了71.05%的总体准确率，这是许多类分类中最高的。然而，我们把重点放在

开发一个计算复杂度较低、分类精度令人满意的模型。我们工作的创新之处在于使用了只使用上三角矩阵数据的技术，将输入的PCC特征图像的大小从32 32减少到23 23。它极大地降低了训练和操作的计算复杂性和时间。

×

×

我们只使用了PCC特征图像和CNN模型。此外，我们在CNN模型中只使用了PCC特征图像；除了这个特征，不需要额外的努力来寻找许多特征。它减少了手动提取特征的麻烦。

5. 总结

在本文中，我们使用了卷积神经网络模型来识别脑电信号中的情绪。尽管使用了原始EEG数据，但为了降低计算复杂性和缩短操作时间，我们考虑了系统开发的PCC特征图像。整个情绪识别的过程是按照使用逻辑回归的分类规则完成的。在这里，我们使用了两种不同的协议；在这两种协议中，我们观察了准确性、模型损失和分类报告。在两类和三类分类中，我们在价值分类任务中取得了78.22%和70.23%的准确性，在唤醒分类任务中取得了74.92%和70.25%的准确性。更高的准确性和实时操作的兼容性是在实际领域中享受情感识别优势的基本前提。因此，未来在通道减少、重要特征提取和深度网络优化方面的更多研究是不可避免的。

竞争性利益的声明

作者没有利益冲突。

参考文献

- [1] P.Romaniszyn-Kania, et al., Affective state during physiotherapy and its analysis using machine learning methods, *Sensors* 21 (14) (2021) 4853, <https://doi.org/10.3390/s21144853>.
- [2] D.Mathersul, L.M. Williams, P.J. Hopkinson, A.H. Kemp, Investigating models of affect: relationships among EEG alpha asymmetry, depression, and anxiety, *Emotion* 8 (4) (2008) 560.
- [3] D.Sammler, M. Grigutsch, T. Fritz, S. Koelsch, Music and emotion: electrophysiological correlates of the processing of pleasant and unpleasant music, *Psychophysiology* 44 (2) (2007) 293-304.
- [4] P. Ackermann, C. Kohlschein, J. Á. Bitsch, K. Wehrle, S. Jeschke, 基于EEG的自动情绪识别：特征提取、选择和分类方法, in:2016年IEEE第18届电子健康网络、应用和服务国际会议, *Healthcom*, 2016, 第1-6页, <https://doi.org/10.1109/HealthCom.2016.7749447>, 2016.
- [5] M.R. Islam, et al., Emotion recognition from EEG signal focusing on deep learning and shallow learning techniques, *IEEE Access* 9 (2021) 94601-94624, <https://doi.org/10.1109/access.2021.3091487>.
- [6] M.M. Rahman, et al., Recognition of human emotions using EEG signals: a review, *Comput.Biol.Med.*(2021) 104696, <https://doi.org/10.1016/j.combiomed.2021.104696>.
- [7] S.M. Alarcão, M.J. Fonseca, Emotions recognition using EEG signals: a survey, *IEEE Trans.Affect.Comput.*10 (3) (2019) 374-393, <https://doi.org/10.1109/taffc.2017.2714671>.
- [8] M.R. Islam, M. Ahmad, 基于小波分析的脑电信号情绪分类, 2019, <https://doi.org/10.1109/ECACE.2019.8679156>.
- [9] W.L. Zheng, B.L. Lu, Investigating critical frequency bands and channels for EEG-based emotion recognition with deep neural networks, *IEEE Trans.Auton.Ment.Dev.*7 (3) (2015) 162-175, <https://doi.org/10.1109/TAMD.2015.2431497>.
- [10] E.Barsoum, C. Zhang, C.C. Ferrer, Z. Zhang, Training deep networks for facial expression recognition with crowd-sourced label distribution, in:第18届ACM国际多模态交互会议论文集, 2016, pp.279-283.
- [11] M.Soleymani, S. Asghari-Esfeden, Y. Fu, M. Pantic, Analysis of EEG signals and facial expressions for continuous emotion detection, *IEEE Trans.Affect.Comput.*7 (1) (2016) 17-28, <https://doi.org/10.1109/TAFCC.2015.2436926>.
- [12] S.R. Kadiri, P. Gangamohan, S.V. Gangashetty, B. Yegnanarayana, Analysis of excitation source features of speech for emotion recognition, in:国际语音通信协会年会议文集, 2015-1月, *INTERSPEECH*, 2015, 第1324-1328页.
- [13] M.T. Valderas, J. Bolea, P. Laguna, M. Vallverdú, R. Bn, Human emotion recognition using heart rate variability analysis with spectral bands based on respiration, in:2015年IEEE医学和生物学工程学会第37届国际年会, *EMBC* , 2015年, 第6134-6137页.
- [14] S.Piana, A. Ho, F. Odone, A. Camurri, Adaptive body gesture representation for automatic emotion recognition, *ACM Trans.Interact.Intell.Syst.*6 (1) (2016) 1-31, <https://doi.org/10.1145/2818740>.
- [15] A.Vaskinn, K. Sundet, T. Østefjells, K. Nymo, I. Melle, T. Ueland, Read emotions from body movement: a generalized impairment in schizophrenia, *Front.Psychol.*6 (Jan) (2016) 2058, <https://doi.org/10.3389/fpsyg.2015.02058>.
- [16] J.Shukla, M. Barreda-Angeles, J. Oliver, G.C. Nandi, D. Puig, Feature extraction and selection for emotion recognition from electrodermal activity, *IEEE Trans.Affect.Comput.*5 (3) (2019) 327-339, <https://doi.org/10.1109/taffc.2019.2901673>.
- [17] K.Schaaff, T. Schultz, Towards emotion recognition from electroencephalographic signals, in:Proceedings - 2009 3rd International Conference on Affective Computing and Intelligent Interaction and Workshops, *ACII*, 2009, pp.1-6, <https://doi.org/10.1109/ACII.2009.5349316>, 2009.
- [18] Z.Mohammadi, J. Frounchi, M. Amiri,使用EEG信号的基于小波的情绪识别系统, *Neural Comput.Appl.* 28 (8) (2017) 1985-1990, <https://doi.org/10.1007/s00521-015-2149-8>.
- [19] S.K. Hadjidimitriou, L.J. Hadjileontiadis, EEG-based classification of music appraisal responses using time-frequency analysis and familiarity ratings, *IEEE Trans.Affect.Comput.*4 (2) (2013) 161-172.
- [20] M.Li, B.-L. Lu, 基于伽马波段EEG的情绪分类, in:2009年IEEE医学和生物学工程学会国际年会, 2009年, 第1223-1226页.
- [21] L.He, D. Hu, M. Wan, Y. Wen, K.M. Von Deneen, M.C. Zhou, Common Bayesian network for classification of EEG-based multiclass motor imagery BCI, *IEEE Trans.Syst.Man, Cybern.Syst.*46 (6) (2016) 843-854, <https://doi.org/10.1109/tsmc.2015.2450680>.
- [22] Y.Velchev, S. Radeva, S. Sokolov, D. Radev, Automated estimation of human emotion from EEG using statistical features and SVM, in:2016年数字媒体产业与学术论坛, *DMIAF*, 2016, 第40-42页.
- [23] M.Chen, J. Han, L. Guo, J. Wang, I. Patras, Identifying valence and arousal levels via connectivity between EEG channels, in:2015年情感计算与智能交互国际会议, *ACII*, 2015, 第63-69页, <https://doi.org/10.1109/ACII.2015.7344552>, 2015.
- [24] M.Soleymani, M. Pantic, T. Pun, Multimodal emotion recognition in response to videos (扩展摘要), in:2015 Int.Conf.Affect.Comput.Intell.Interact, vol. 3, *ACII*, 2015, pp. 491-497, <https://doi.org/10.1109/ACII.2015.7344615>, 2015.
- [25] W.L. Zheng, J.Y. Zhu, B.L. Lu, Identifying stable patterns over time for emotion recognition from eeg, *IEEE Trans.Affect.Comput.*10 (2019) 417-429, <https://doi.org/10.1109/TAFCC.2017.2712143>, 3.
- [26] J.Atkinson, D. Campos, Improving BCI-based emotion recognition by combining EEG feature selection and kernel classifiers, *Expert Syst.*47 (2016) 35-41, <https://doi.org/10.1016/j.eswa.2015.10.049>.
- [27] M. Ångkvist, L. Karlsson, A. Loutfi, 使用无监督的特征学习进行睡眠阶段分类, *Adv.Artif.Neural Syst.*2012 (2012).
- [28] K.Li, X. Li, Y. Zhang, A. Zhang, Affective state recognition from EEG with deep belief networks, in:2013年IEEE生物信息学和生物医学国际会议, 2013, pp.305-310.
- [29] H.P. Martinez, Y. Bengio, G. Yannakakis, Learning deep physiological models of affect, *IEEE Comput.Intell.Mag.*8 (2) (2013) 20-33, <https://doi.org/10.1109/mci.2013.2247823>.
- [30] Z.Wen, R. Xu, J. Du, "A Novel Convolutional Neural Networks for Emotion Recognition Based on EEG Signal," in 2017 International Conference on Security, Pattern Analysis, and Cybernetics, *SPAC*, 2017, pp.672-677.
- [31] S.Tripathi, S. Acharya, R.D. Sharma, S. Mittal, S. Bhattacharya, Using deep and convolutional neural networks for accurate emotion classification on DEAP dataset, in:第三十一届AAAI人工智能会议论文集, 2017, 第4746-4752页[在线]. Available: <https://www.aaai.org/ocs/index.php/IAAI/IAAI17/paper/view/15007/13731>.
- [32] H.Mei, X. Xu, EEG-based emotion classification using convolutional neural network, in:2017 International Conference on Security, Pattern Analysis, and Cybernetics, *SPAC* , 2017, pp.130-135.
- [33] M.R. Islam, M. Ahmad, Virtual Image from EEG to Recognize Appropriate Emotion Using Convolutional Neural Network, 2019, <https://doi.org/10.1109/ICASERT.2019.8934760>.
- [34] S.Koelstra, et al., DEAP: a database for emotion analysis; Using physiological signals, *IEEE Trans.Affect.Comput.*3 (1) (2012) 18-31, <https://doi.org/10.1109/t-affc.2011.15>.
- [35] S.Jirayucharoensak, S. Pan-Ngum, P. Israsena, EEG-based emotion recognition using deep learning network with principal component based covariate shift adaptation, *Sci. World J.* 2014 (2014) , <https://doi.org/10.1155/2014/627892>.
- [36] T.Song, W. Zheng, P. Song, Z. Cui, EEG emotion recognition using dynamical graph convolutional neural networks, *IEEE Trans.Affect.Comput.*11 (3) (2018) 532-541.
- [37] J.Cheng, et al., Emotion recognition from multi-channel EEG via deep forest, *IEEE J.Biomed.愈合*. Informatics 25 (2) (2021) 453-464, <https://doi.org/10.1109/JBHI.2020.2995767>.
- [38] Y.Fang, H. Yang, X. Zhang, H. Liu, B. Tao, Multi-feature input deep forest for EEG-based emotion recognition, *Front.Neurorob.*14 (2021) 617531, <https://doi.org/10.3389/fnbot.2020.617531>.
- [39] D.Maheshwari, S.K. Ghosh, R.K. Tripathy, M. Sharma, U.R. Acharya, Automated accurate emotion recognition system using rhythm specific deep convolutional neural network technique with multi-channel EEG signals, *Comput.Biol.Med.*134 (2021) 104428.